

Detección de defectos en objetos en movimiento mediante Redes Neuronales Convolucionales con optimizaciones específicas para hardware NVIDIA

Alumno: Haro Armero, Abel

Tutor: Flich Cardo, José


Co-tutor: López Rodríguez, Pedro Juan

Fecha: 15 de julio de 2025

1. Introducción
2. Motivación
3. Objetivos
4. Conceptos previos
5. Propuesta de solución
6. Desarrollo de la solución
7. Demo del sistema
8. Resultados
9. Conclusiones


1. Introducción

- Crecimiento exponencial de la **Inteligencia Artificial**.
- Avances en **visión por computador** gracias a las **CNNs**.
- **Desafíos energéticos** impulsan soluciones optimizadas.
- Dispositivos optimizados para **IA en entornos embebidos**.
- Desarrollo de sistema de **detección de defectos** en objetos en movimiento con CNNs, optimizado para hardware **NVIDIA**.



2. Motivación

- Emular la **interpretación humana** de imágenes en máquinas.
- **IA y visión por computador** revolucionan la tecnología.
- **NVIDIA Jetson** impulsa la IA en **edge computing**.
- Automatización de la **detección y clasificación** de objetos en movimiento en la industria.




3. Objetivos

- Estudiar el estado del arte en **CNNs, aceleradores hardware**.
- Crear un **conjunto de datos** para entrenamiento y evaluación.
- Entrenar y validar diferentes **modelos CNN** para detección de defectos en **tiempo real**.
- Implementar un **sistema de visión artificial** integrado con hardware NVIDIA.
- Analizar y optimizar **cuellos de botella** para mejorar rendimiento y consumo energético.
- Evaluar el sistema con métricas de **precisión, latencia y consumo**.
- Realizar un **análisis comparativo** para encontrar la configuración óptima.


4. Conceptos Previos - Redes Neuronales Convolucionales (CNNs)

- Las CNNs son un tipo de red neuronal profunda diseñadas para procesar datos con una estructura matricial, como imágenes.
- El objetivo es localizar dentro de una imagen objetos y clasificarlos, detectando defectos o características específicas.
- Utilizan capas convolucionales para extraer características jerárquicas.
- Existen dos tipos principales de CNNs, detectores de dos etapas como R-CNN y detectores de una etapa como YOLO.




4. Conceptos Previos - Hardware NVIDIA Jetson

- Arquitecturas hardware especializadas para el deep learning.
- NVIDIA Jetson: SoC (System on a Chip) que integra CPU y GPU para eficiencia energética y procesamiento paralelo.
- Jetpack SDK y TensorRT: El SDK de NVIDIA proporciona herramientas para desarrollar aplicaciones de IA, incluyendo TensorRT para optimizar de manera eficiente las redes neuronales en el hardware de NVIDIA.




4. Conceptos Previos - Seguimiento de objetos (MOT)

- El seguimiento de objetos es una técnica que permite identificar y seguir la trayectoria de un objeto a lo largo del tiempo en una secuencia de imágenes.
- Rastrea objetos combinando detección y análisis de movimiento.
- BYTETrack es el algoritmo de seguimiento que realiza el seguimiento de objetos a partir de las detecciones de un detector de objetos.




5. Propuesta de solución




6. Desarrollo de la solución - Entrenamiento y validación de modelos

- Creación de un conjunto de datos con imágenes de canicas de distintos colores y defectos.
- Entrenamiento de modelos CNN para detección de defectos.
- Validación y ajuste de hiperparámetros para mejorar precisión.
- Exportación de los modelos a TensorRT para optimizar su rendimiento en hardware NVIDIA.



6. Desarrollo de la solución - Segmentación de las etapas (1/5)


- El sistema se divide en cuatro etapas, captura de vídeo, detección de objetos, seguimiento de objetos y escritura de resultados.
- El objetivo de segmentar las etapas es permitir que cada una de ellas operen de forma independiente para mejorar la velocidad y eficiencia del sistema.
- Se han propuesto cuatro formas de segmentación para mejorar el procesamiento secuencial, (1) segmentación por **hilos**, (2) segmentación por **procesos**, (3) segmentación por **procesos con memoria compartida** y (4) segmentación por **heterogénea**



6. Desarrollo de la solución - Segmentación de las etapas (2/5)

1. Segmentación por hilos:


- Cada etapa se ejecuta en un hilo separado.
- ↑ La información se comparte entre hilos mediante colas que se consumen de forma asíncrona.
- ↓ Permite un procesamiento paralelo pero no concurrente debido al GIL (Global Interpreter Lock) de Python.



6. Desarrollo de la solución - Segmentación de las etapas (3/5)

2. Segmentación por procesos:


- Cada etapa se ejecuta en un **proceso separado**.
- ↑ Permite un **procesamiento concurrente**, pero con mayor latencia en la comunicación.
- ↓ La comunicación entre procesos se realiza mediante **colas** implementadas sobre **pipes**.



6. Desarrollo de la solución - Segmentación de las etapas (4/5)

3. Segmentación por procesos con memoria compartida:


- Cada etapa se ejecuta en un proceso separado, pero **comparten memoria**.
- ↑ Permite un procesamiento concurrente con **menor latencia** en la comunicación.
- Las colas de comunicación se implementan sobre **memoria compartida** entre procesos evitando la sobrecarga de pipes.



6. Desarrollo de la solución - Segmentación de las etapas (5/5)


4. Segmentación por heterogénea:

- Se puede ejecutar tanto con **hilos** como con **procesos** (con y sin memoria compartida).
- Ejecuta la etapa de de detección en la **GPU o DLA** del dispositivo Jetson.
- ↑ Teóricamente permite **explotar todos los recursos** para mejorar el rendimiento.
- ↓ Los modelos de no se ejecutan completamente en la **DLA**.



6. Desarrollo de la solución - Prueba de concepto

Como prueba simple de concepto, se ha construido una pequeña cinta transportadora con un motor. El sistema captura el vídeo de la cinta transportadora y detecta canicas de distintos colores y defectos. El objetivo es demostrar que el sistema es capaz de detectar objetos en movimiento y clasificarlos en tiempo real.



7. Demo del sistema

Frame: 187





8. Resultados

- Para evaluar el rendimiento del sistema, se han realizado pruebas con diferentes configuraciones de segmentación y optimización. Los resultados se han medido en términos de precisión, latencia y consumo energético.
- Existen todas estas configuraciones para evaluar el rendimiento del sistema:
 - Cantidad de objetos media en el vídeo: {17, 43, 84, carga variable}
 - Tipo de segmentación: {hilos, procesos, procesos con memoria compartida y heterogénea}
 - Tipo de modelo y talla: {YOLOv5{nu, mu}, YOLOv8{n, s}, YOLO11{n, s, m, l}}
 - Precisión del modelo: {FP32, FP16, INT8}
 - Modo de energía del dispositivo Jetson: {MAXN, 30W8core, 30W4core, 15W4core, etc}
 - Dispositivo Jetson: {Jetson AGX Xavier, Jetson AGX Orin, Jetson Orin Nano}

8. Resultados - Cantidad de objetos

- Se ha evaluado el rendimiento del sistema con diferentes **cantidades de objetos** en el vídeo.
- **4 vídeos**, (1) media de **17 objetos**, (2) media de **43 objetos**, (3) media de **84 objetos** y (4) **carga variable** de 0 a 180 objetos.
- Para el resto de la configuración se ha utilizado los **parámetros más óptimos** encontrados en la sección de análisis comparativo.
- Tras un análisis de regresión, se ha encontrado que la cantidad de objetos máxima para que el sistema es capaz de procesar en tiempo real a **30 FPS** es de **100 objetos**.



8. Resultados - Tipo de segmentación

- Se ha evaluado el rendimiento del sistema con diferentes tipos de **segmentación**.
- Se han utilizado el video con una media de **84 objetos**.
- Para el resto de la configuración se ha utilizado los **parámetros más óptimos** encontrados en la sección de análisis comparativo.

Segmentación	Frames	Tiempo (s) ↓	FPS ↑	LFPS ↓	Potencia (W) ↓	Energía (J) ↓	F/W ↓	Speedup ↑	GPU (%) ↓	CPU (%) ↓
Secuencial	2400	198.57	12.09	0.00	9.488	1884.03	1.274	1.000	24.62	15.46
Hilos	2400	131.40	18.26	0.00	12.991	1703.12	1.409	1.511	10.35	25.53
Multiprocesos	2400	105.16	22.82	0.00	14.272	1500.58	1.599	1.888	12.84	33.65
MP Memoria Compartida	2400	80.27	29.90	0.00	16.551	1320.25	1.818	2.474	17.12	40.10
Heterogénea	2400	84.36	28.45	0.00	17.812	1502.39	1.597	2.354	10.00	44.25

9. Conclusiones – Cumplimiento de objetivos (1/2)

Los objetivos del TFG se han alcanzado con éxito:

- **Estudio del estado del arte:** Se realizó un análisis exhaustivo de **CNNs**, **aceleradores hardware** y plataformas **NVIDIA Jetson**, superando desafíos de compatibilidad y configuración en arquitectura ARM64.
- **Creación del conjunto de datos:** Se generó un **dataset** y vídeos de entrenamiento que simulan condiciones reales de operación con objetos de variabilidad controlada.
- **Entrenamiento de modelos CNN:** Se entrenaron múltiples modelos de las familias **YOLOv5**, **YOLOv8** y **YOLO11** en diversas precisiones, optimizando hiperparámetros mediante iteraciones exhaustivas.

9. Conclusiones – Cumplimiento de objetivos (2/2)

- **Implementación del sistema integrado:** Se desarrolló un sistema de **visión artificial** que combina detección con seguimiento **BYTETrack**, manteniendo la identidad de objetos a lo largo del tiempo.
- **Análisis y optimización de cuellos de botella:** Se exploraron estrategias de segmentación (**hilos, procesos, memoria compartida, heterogénea**), identificando la **segmentación por procesos con memoria compartida** como la más efectiva.
- **Evaluación con métricas completas:** Se realizaron experimentos exhaustivos evaluando **precisión, latencia y consumo** en diferentes configuraciones de hardware Jetson.

Detección de defectos en objetos en movimiento mediante Redes Neuronales Convolucionales con optimizaciones específicas para hardware NVIDIA

Alumno: Haro Armero, Abel

Tutor: Flich Cardo, José

Co-tutor: López Rodríguez, Pedro Juan

Fecha: 15 de julio de 2025